

Análise de Agrupamento (*Clustering*) de Indicadores de Saúde para Identificação de Perfis de Risco de Diabetes

Ana Lilian Alfonso Toledo¹, Tobias Viero de Oliveira¹

¹Curso de Ciência da Computação – Universidade Federal de Santa Maria (UFSM)

1. Introdução e Definição do Problema

A diabetes *mellitus* tipo 2 é uma das doenças crônicas de maior prevalência mundial e está fortemente associada a fatores de risco metabólicos e comportamentais, como hipertensão, obesidade, colesterol elevado e baixo nível de atividade física. A identificação de subgrupos da população que compartilham perfis de risco semelhantes é uma tarefa de interesse para a saúde pública, pois permite direcionar ações de prevenção.

Este trabalho aplica algoritmos de agrupamento (*clustering*), uma técnica de aprendizado não supervisionado, a um conjunto de dados real de indicadores de saúde. O problema que buscamos resolver é o seguinte:

Ao remover o diagnóstico de diabetes, os algoritmos de clustering conseguem separar os respondentes em grupos com perfis de risco distintos (por exemplo, um grupo saudável e um grupo de alto risco metabólico)? Os clusters encontrados se alinham ao rótulo original de diabetes? Quais variáveis mais separam os grupos?

Coerentemente com a natureza não supervisionada da tarefa, o rótulo de diabetes (`Diabetes_binary`) foi removido antes da execução de qualquer algoritmo. Ele é reintroduzido apenas ao final, para avaliar e interpretar externamente a qualidade dos agrupamentos.

2. Descrição do Dataset

Foi utilizado o conjunto *CDC Diabetes Health Indicators*, derivado do *Behavioral Risk Factor Surveillance System* (BRFSS) de 2015 dos *Centers for Disease Control and Prevention* [Centers for Disease Control and Prevention 2015]. Utilizou-se a versão balanceada (50–50) disponibilizada por [Teboul 2021], com 70.692 instâncias (acima do mínimo exigido de 1.000) e 21 variáveis preditoras mais o rótulo `Diabetes_binary`. O conjunto é real (não sintético) e foi empregado em estudo científico de modelagem de risco de diabetes com técnicas de aprendizado de máquina [Xie et al. 2019], que serve de referência para este trabalho.

As 21 variáveis preditoras podem ser organizadas em três tipos, distinção que orientou tanto a análise descritiva quanto o pré-processamento:

- **Binárias (14):** `HighBP`, `HighChol`, `CholCheck`, `Smoker`, `Stroke`, `HeartDiseaseorAttack`, `PhysActivity`, `Fruits`, `Veggies`, `HvyAlcoholConsump`, `AnyHealthcare`, `NoDocbcCost`, `DiffWalk` e `Sex`;
- **Contínuas (3):** `BMI` (índice de massa corporal), `MentHlth` e `PhysHlth` (dias de saúde mental e física ruim no último mês);
- **Ordinais (4):** `GenHlth` (saúde geral, 1–5), `Age` (faixa etária, 1–13), `Education` (1–6) e `Income` (1–8).

2.1. Análise Univariada

A Tabela 1 resume as estatísticas descritivas das principais variáveis numéricas. Destaca-se o BMI, com média de 29,9 (faixa de sobrepeso) e máximo de 98, um valor implausível que sinaliza a presença de *outliers* a serem tratados. As variáveis *MentHlth* e *PhysHlth* apresentam mediana zero e médias baixas (3,8 e 5,8 dias), indicando forte assimetria à direita: a maioria dos respondentes relata nenhum dia ruim, mas uma minoria relata até 30 dias.

Tabela 1. Estatísticas descritivas das principais variáveis numéricas ($n = 70.692$).
Age, GenHlth, Education e Income são códigos ordinais.

Variável	Média	Desv.	Mín.	Q1	Mediana	Máx.
BMI	29,86	7,11	12	25	29	98
MentHlth	3,75	8,16	0	0	0	30
PhysHlth	5,81	10,06	0	0	0	30
GenHlth	2,84	1,11	1	2	3	5
Age	8,58	2,85	1	7	9	13
Education	4,92	1,03	1	4	5	6
Income	5,70	2,18	1	4	6	8

A distribuição do BMI (Figura 1) confirma a concentração na faixa de 20 a 40 e uma cauda longa à direita, com poucos registros acima de 60. Pela regra do intervalo interquartil (IQR), valores acima de aproximadamente 45 já são considerados atípicos; optamos, contudo, por uma faixa fisiologicamente plausível ($12 \leq \text{BMI} \leq 60$) no tratamento de *outliers*, descrito na Seção 3.




Figura 1. Histograma do índice de massa corporal (BMI). A distribuição é assimétrica à direita, com cauda longa indicando valores extremos.

Para as 14 variáveis binárias, a Figura 2 mostra a proporção de respostas iguais a 1. Variáveis como *CholCheck* (97,5%) e *AnyHealthcare* (95,5%) são quase constantes e, portanto, pouco informativas para separar grupos. Já fatores de risco relevantes

aparecem em parcela expressiva da amostra: HighBP (56,3%), HighChol (52,6%) e DiffWalk (25,3%).




Figura 2. Proporção de respostas iguais a 1 nas variáveis binárias, ordenadas de forma decrescente.

2.2. Análise Bivariada

Foram calculadas as correlações de Pearson e de Spearman entre as variáveis numéricas. Os pares mais fortemente associados (Spearman) foram GenHlth–PhysHlth ($\rho = 0,52$), Education–Income ($\rho = 0,46$) e GenHlth–Income ($\rho = -0,38$). Esses valores são coerentes: pior saúde geral acompanha mais dias de saúde física ruim, e maior escolaridade acompanha maior renda. A maior divergência entre Pearson e Spearman ocorreu justamente no par GenHlth–PhysHlth (Pearson 0,55 contra Spearman 0,52), reflexo da natureza ordinal e discreta dessas variáveis. A Figura 3 ilustra essa relação por um gráfico de dispersão (com *jitter* para tornar visíveis os pontos discretos sobrepostos).




Figura 3. Dispersão entre GenHlth e PhysHlth (amostra de 5.000 pontos). À medida que a saúde geral piora (valores maiores de GenHlth), cresce o número de dias de saúde física ruim.

Nenhum par apresentou correlação suficientemente alta (próxima de $\pm 0,9$) para justificar a remoção de variáveis por redundância; todas as 21 *features* foram mantidas.

2.3. Análise Multivariada

A Figura 4 apresenta o *heatmap* da matriz de correlação de Spearman das 21 variáveis. Observa-se um bloco de fatores de risco metabólicos mutuamente correlacionados (HighBP, HighChol, HeartDiseaseorAttack, Stroke, DiffWalk, GenHlth) e um bloco socioeconômico (Education, Income), com correlação negativa entre ambos. Essa estrutura sugere que existem, de fato, eixos latentes de variação na população.




Figura 4. Matriz de correlação de Spearman das 21 variáveis preditoras. Tons avermelhados indicam correlação positiva e azulados, negativa.

Para visualizar a estrutura geral, aplicou-se a Análise de Componentes Principais (PCA) sobre os dados padronizados (Figura 5). A primeira componente explica apenas 17,3% da variância e as duas primeiras, juntas, 25,6%. São necessárias 17 das 21 componentes para atingir 90% da variância acumulada. Esse resultado indica que a informação está distribuída entre muitas variáveis e que não há poucas dimensões dominantes, um indício, desde já, de que os agrupamentos tenderão a ser pouco separados no espaço completo.




Figura 5. Scree plot do PCA: variância explicada por componente (barras) e variância acumulada (linha). A linha tracejada marca o patamar de 90%, atingido somente na 17ª componente.

3. Pré-processamento

O pré-processamento seguiu os passos exigidos pela tarefa:

1. **Valores faltantes:** a verificação não encontrou nenhum NaN no conjunto, dispensando imputação.
2. **Colunas desnecessárias:** verificou-se a ausência de colunas de índice/ID; nenhuma precisou ser removida.
3. **Tratamento de outliers:** o BMI foi limitado (*clipping*) à faixa plausível de 12 a 60, corrigindo os valores extremos identificados na análise univariada sem descartar instâncias.
4. **Remoção do rótulo:** a coluna `Diabetes_binary` foi separada e nunca entrou nos algoritmos, conforme a regra do aprendizado não supervisionado.
5. **Padronização:** aplicou-se `StandardScaler` (média 0 e desvio 1) a todas as variáveis. Isso impede que atributos de grande escala, como BMI, Age ou Income, dominem as variáveis binárias no cálculo de distâncias.
6. **PCA (decisão):** o PCA foi usado para visualização (2 componentes) e como diagnóstico. Como atingir 90% da variância exigiria 17 componentes (ganho pequeno em dimensionalidade), optou-se por executar a clusterização sobre as 21 dimensões padronizadas, preservando a interpretabilidade dos perfis.
7. **Verificação final:** confirmou-se que a matriz de entrada é 100% numérica e livre de NaN.

Por questão de custo computacional (`Agglomerative` e `DBSCAN` possuem complexidade $O(n^2)$), esses dois algoritmos foram executados sobre uma amostra aleatória fixa de 7.000 instâncias, enquanto o `K-Means` rodou sobre as 70.692 instâncias completas.

4. Algoritmos e Hiperparâmetros

Foram implementados, com a biblioteca *scikit-learn*, os três algoritmos exigidos, cada um com diferentes hiperparâmetros. A qualidade de cada configuração foi medida por

três métricas internas: Silhouette (maior é melhor), Davies-Bouldin (menor é melhor) e Calinski-Harabasz (maior é melhor).

4.1. K-Means

Testou-se k de 2 a 10 (com `n_init = 10`). A Tabela 2 apresenta os resultados. O *método do cotovelo* (Figura 6, à esquerda) mostra queda suave e contínua da inércia, sem um “cotovelo” nítido. Já o *Silhouette* (Figura 6, à direita) é claramente maximizado em $k = 2$ (0,167), caindo bruscamente para os demais valores. Selecionou-se, portanto, $k = 2$.

Tabela 2. K-Means: métricas internas em função de k . A melhor linha (por *Silhouette*) está destacada.

k	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	0,167	2,544	9645
3	0,077	2,883	7170
4	0,084	2,535	6391
5	0,085	2,317	5920
6	0,091	2,244	5509
7	0,100	2,079	5476
8	0,095	2,250	5050
9	0,083	2,133	5119
10	0,103	2,069	5021




Figura 6. K-Means. À esquerda, método do cotovelo (inércia decrescente sem ponto de inflexão claro). À direita, *Silhouette* em função de k , com máximo em $k = 2$.

4.2. Agglomerative Clustering

Testaram-se quatro métodos de *linkage* (*ward*, *complete*, *average* e *single*) combinados com $k \in \{2, 3, 4, 5\}$ sobre a amostra de 7.000 instâncias. A Tabela 3 resume as configurações representativas. Embora *average* e *single* alcancem valores de *Silhouette* mais altos ($\approx 0,34$), eles produzem partições degeneradas, em que um dos clusters contém menos de 1% dos pontos, ou seja, isolam um punhado de *outliers* e deixam todo o resto em um único grupo. Para evitar essa armadilha, a seleção exigiu que o menor cluster contivesse ao menos 5% das amostras. Sob esse critério, a melhor configuração foi *complete* com $k = 2$ (*Silhouette* = 0,242).

Tabela 3. Agglomerative: configurações representativas. “Menor cluster” é a fração de pontos no menor grupo; partições com fração muito baixa são degeneradas. A configuração selecionada está destacada.

Linkage	k	Menor cluster	Silhouette	D-B	C-H
ward	2	0,371	0,111	3,140	634
complete	2	0,103	0,242	2,981	370
complete	5	0,025	0,227	1,614	430
average	2	0,001	0,341	1,199	9
single	2	0,025	0,327	1,285	377

O dendrograma (Figura 7), gerado por *ward* sobre uma subamostra de 1.500 pontos, mostra que um corte alto separa naturalmente a amostra em poucos grandes ramos, reforçando que a estrutura dominante dos dados é de baixa cardinalidade de grupos.




Figura 7. Dendrograma (*linkage ward*, subamostra de 1.500 pontos). Um corte horizontal alto divide os dados em poucos grupos principais.

4.3. DBSCAN

Estimou-se a vizinhança via gráfico de k -distance (Figura 8, à esquerda), cujo “joelho” fica em torno de $\varepsilon \approx 3,0$ a $4,0$ no espaço padronizado de 21 dimensões. Testou-se a grade $\varepsilon \in \{1,0; 1,5; 2,0; 2,5; 3,0\}$ e $\text{min_samples} \in \{5, 10, 20, 50\}$. Muitas configurações atingiram *Silhouette* alto apenas porque rotularam a maior parte dos pontos como ruído. Aplicando o critério de validade (menos de 50% de ruído e entre 2 e 10 clusters), a melhor configuração foi $\varepsilon = 3,0$ e $\text{min_samples} = 10$, que gerou 7 clusters e 1.564 pontos de ruído ($\approx 22\%$ da amostra), com *Silhouette* = 0,137. A Tabela 4 ilustra o dilema entre *Silhouette* e fração de ruído.

Tabela 4. DBSCAN: configurações selecionadas, evidenciando o compromisso entre *Silhouette* e proporção de ruído (amostra de 7.000). A configuração escolhida está destacada.

ε	min_samples	Nº clusters	Ruído	Silhouette
1,0	20	2	6783	0,408
1,5	50	3	6591	0,323
2,0	50	12	5702	0,253
3,0	5	14	1165	0,147
3,0	10	7	1564	0,137




Figura 8. DBSCAN. À esquerda, gráfico de *k-distance* (10º vizinho) usado para estimar ε . À direita, os clusters projetados em 2D via PCA; os pontos em cinza são ruído.

5. Comparação entre Algoritmos

A Tabela 5 reúne a melhor configuração de cada algoritmo, e a Figura 9 compara visualmente as três métricas internas.

Tabela 5. Comparação entre a melhor configuração de cada algoritmo.

Algoritmo	Configuração	Clusters	Silhouette	D-B	C-H
K-Means	$k = 2$	2	0,167	2,544	9645
Agglomerative	<i>complete</i> , $k = 2$	2	0,242	2,981	370
DBSCAN	$\varepsilon = 3,0$, m.s.= 10	7	0,137	1,478	153




Figura 9. Comparação das três métricas internas entre os algoritmos. Cada métrica favorece um algoritmo diferente.

A comparação revela que nenhum algoritmo domina em todas as métricas, o que é esperado dado que cada métrica privilegia uma propriedade distinta da partição:

- O **Agglomerative** obteve o melhor *Silhouette* (0,242), favorecido por trabalhar apenas na amostra menor e por isolar um grupo compacto.
- O **DBSCAN** obteve o melhor *Davies-Bouldin* (1,478), pois ao remover o ruído sobram clusters internamente mais homogêneos.
- O **K-Means** obteve, de longe, o melhor *Calinski-Harabasz* (9645), métrica sensível ao tamanho da amostra (ele foi o único a rodar sobre as 70.692 instâncias completas).

Os valores absolutos de *Silhouette* são, em todos os casos, baixos ($\leq 0,25$). Isso confirma o diagnóstico do PCA: os dados não formam grupos densos e bem separados, mas sim uma nuvem contínua atravessada por gradientes de risco. As projeções em 2D (Figura 10) ilustram esse ponto: o K-Means corta a nuvem ao longo da primeira componente, enquanto o Agglomerative produz uma divisão mais irregular.




Figura 10. Clusters projetados em 2D via PCA. À esquerda, K-Means ($k = 2$), que separa a nuvem ao longo de PC1. À direita, Agglomerative (*complete*, $k = 2$), com fronteira menos regular.

6. Interpretação dos Clusters com o Rótulo

Reintroduzindo o rótulo `Diabetes_binary` apenas para avaliação, calculou-se o *Adjusted Rand Index* (ARI) de cada algoritmo. Os valores foram baixos (K-Means = 0,113; DBSCAN = 0,008; Agglomerative = 0,003), mostrando que nenhum agrupamento reproduz fielmente o diagnóstico, o que é coerente, pois diabetes não é determinada por um único eixo de variação dos dados. Ainda assim, o K-Means foi o que mais se alinhou ao rótulo, e sua interpretação é a mais clara e útil.

A Tabela 6 mostra o perfil médio dos dois clusters do K-Means, com as variáveis-chave de risco. A separação é nítida e clinicamente interpretável:

- **Cluster 0 — “alto risco metabólico”** (23.515 pessoas): alta prevalência de pressão alta (81%) e colesterol alto (71%), BMI médio elevado (32,6), pior saúde geral (3,84), população mais idosa e grande dificuldade de locomoção (67%). Nesse grupo, 75% têm diabetes.
- **Cluster 1 — “baixo risco”** (47.177 pessoas): metade da prevalência de pressão e colesterol altos, BMI menor (28,4), melhor saúde geral (2,34) e praticamente sem dificuldade de locomoção (4%). Nesse grupo, a taxa de diabetes cai para 37%.

Tabela 6. Perfil médio dos dois clusters do K-Means (variáveis-chave). A “taxa de diabetes” é a proporção do rótulo original em cada grupo, usada apenas para interpretação.

Variável	Cluster 0 (alto risco)	Cluster 1 (baixo risco)
<i>n</i> (pessoas)	23.515	47.177
HighBP	0,81	0,44
HighChol	0,71	0,43
BMI	32,6	28,4
GenHlth (1–5)	3,84	2,34
Age (faixa)	9,46	8,15
DiffWalk	0,67	0,04
PhysHlth (dias)	14,3	1,58
Taxa de diabetes	0,75	0,37

A Tabela 7 apresenta a tabela de contingência entre os clusters do K-Means e o rótulo. Embora não haja separação perfeita, observa-se um enriquecimento claro: o Cluster 0 concentra a maioria dos casos de diabetes, enquanto os não diabéticos predominam no Cluster 1.

Tabela 7. Tabela de contingência entre os clusters do K-Means e o rótulo `Diabetes_binary` (0 = sem diabetes; 1 = com diabetes).

	Sem diabetes (0)	Com diabetes (1)
Cluster 0 (alto risco)	5.821	17.694
Cluster 1 (baixo risco)	29.525	17.652

7. Discussão e Conclusão

Retomando as perguntas que definiram o problema:

- **Os algoritmos separam grupos de risco distintos?** Sim, parcialmente. O K-Means produziu uma divisão limpa e interpretável entre um grupo de alto risco metabólico e um grupo mais saudável, exatamente como hipotetizado.
- **Os clusters se alinham ao rótulo?** Apenas de forma fraca ($ARI = 0,11$ no melhor caso). A diabetes não é separável por um único eixo dos dados, e os grupos refletem um gradiente de risco mais do que uma fronteira nítida.
- **Quais variáveis mais separam os grupos?** `HighBP`, `BMI`, `GenHlth`, `DiffWalk` e `PhysHlth` foram as que mais distinguiram os perfis, confirmando os fatores de risco clássicos de diabetes tipo 2.

Quanto à comparação entre algoritmos, o K-Means foi o mais adequado ao problema: escalou para o conjunto completo, produziu a partição mais interpretável e a de maior alinhamento ao rótulo. O Agglomerative ofereceu o melhor *Silhouette*, mas a um custo computacional que o limitou à amostra. O DBSCAN mostrou-se inadequado para dados de alta dimensão e densidade aproximadamente uniforme: classificou parte expressiva da amostra como ruído e não encontrou clusters densos bem definidos.

A principal lição do experimento, evidenciada de forma convergente pelo PCA, pelos baixos valores de *Silhouette* e pelos baixos ARIs, é que os indicadores de saúde do BRFSS formam uma nuvem contínua de risco, sem fronteiras naturais nítidas. Ainda assim, a clusterização cumpriu seu papel exploratório, revelando subpopulações de risco coerentes com o conhecimento clínico sobre a diabetes tipo 2.

Referências

- Centers for Disease Control and Prevention (2015). Behavioral risk factor surveillance system (brfss) 2015. <https://www.cdc.gov/brfss/>.
- Teboul, A. (2021). Diabetes health indicators dataset. Kaggle. <https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>.
- Xie, Z., Nikolayeva, O., Luo, J., and Li, D. (2019). Building risk prediction models for type 2 diabetes using machine learning techniques. *Preventing Chronic Disease*, 16:E130.