

Análise de Agrupamento (*Clustering*) de Indicadores de Saúde para Identificação de Perfis de Risco de Diabetes

Ana Lilian Alfonso Toledo¹, Tobias Viero de Oliveira¹

¹Curso de Ciência da Computação – Universidade Federal de Santa Maria (UFSM)

1. Introdução e Definição do Problema

A diabetes *mellitus* tipo 2 é uma doença crônica associada a fatores metabólicos, comportamentais e socioeconômicos. Pressão alta, colesterol elevado, excesso de peso, sedentarismo, idade, dificuldade de locomoção e pior percepção de saúde são variáveis frequentemente relacionadas ao aumento do risco da doença. Em bases populacionais de saúde, essas características dificilmente aparecem isoladas: em geral, elas se combinam em perfis mais amplos de risco. Por esse motivo, a aplicação de métodos de agrupamento é útil como etapa exploratória, pois permite investigar se existem subpopulações com padrões semelhantes mesmo sem utilizar o rótulo de diagnóstico durante o treinamento.

Este trabalho aplica algoritmos de agrupamento (*clustering*) a um conjunto real de indicadores de saúde relacionados ao diabetes. A tarefa não é construir um classificador supervisionado, mas verificar se a própria estrutura das variáveis de saúde permite separar respondentes em grupos interpretáveis. Assim, o problema definido para o experimento é:

Ao remover o diagnóstico de diabetes, os algoritmos de clustering conseguem separar os respondentes em grupos com perfis de risco distintos, como um grupo de maior risco metabólico e outro de menor risco? Em que medida esses grupos se alinham ao rótulo original de diabetes? Quais variáveis mais explicam a diferença entre os perfis encontrados?

Seguindo a natureza não supervisionada do problema, a coluna `Diabetes_binary` foi removida antes da execução de todos os algoritmos. O rótulo foi reintroduzido apenas após a clusterização, exclusivamente para avaliar e interpretar os agrupamentos. Essa separação é importante porque evita vazamento de informação: os algoritmos devem descobrir padrões a partir dos indicadores de saúde, e não a partir da resposta que se deseja analisar.

2. Descrição do Dataset

Foi utilizado o conjunto *CDC Diabetes Health Indicators*, derivado do *Behavioral Risk Factor Surveillance System* (BRFSS) de 2015, dos *Centers for Disease Control and Prevention* [1]. A versão usada foi a versão balanceada 50–50 disponibilizada por Teboul [2], com 70.692 instâncias e 22 colunas: 21 variáveis preditoras e o rótulo `Diabetes_binary`. O conjunto é real, possui mais de 1.000 registros e está diretamente relacionado ao problema de diabetes. Além disso, o mesmo tipo de base já foi utilizado em estudo científico sobre predição de diabetes com técnicas de aprendizado de máquina [3].

Um ponto relevante para a interpretação dos resultados é que a versão utilizada é balanceada em relação ao rótulo de diabetes. Portanto, as proporções de pessoas com diabetes observadas nos clusters não devem ser lidas como prevalência real da doença na

população. Elas servem como medida externa de alinhamento entre os agrupamentos e o diagnóstico registrado na base.

As variáveis preditoras foram organizadas em três grupos, pois cada tipo de atributo tem papel diferente na análise descritiva e no pré-processamento:

- **Variáveis binárias (14):** HighBP, HighChol, CholCheck, Smoker, Stroke, HeartDiseaseorAttack, PhysActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, DiffWalk e Sex;
- **Variáveis contínuas (3):** BMI, MentHlth e PhysHlth;
- **Variáveis ordinais (4):** GenHlth, Age, Education e Income.

3. Análise Descritiva

A análise descritiva foi conduzida antes da clusterização para compreender a estrutura dos dados, detectar valores extremos e decidir quais transformações seriam necessárias. Ela foi dividida em três níveis: univariado, bivariado e multivariado.

3.1. Análise Univariada

A Tabela 1 apresenta as estatísticas das principais variáveis numéricas. O BMI tem média de 29,86 e mediana de 29, valor compatível com uma amostra concentrada na faixa de sobrepeso. O máximo de 98, por outro lado, é um valor extremo e pouco plausível em termos fisiológicos, indicando a necessidade de tratamento de *outliers*. Já MentHlth e PhysHlth apresentam mediana zero, mas máximos de 30 dias. Isso revela distribuições assimétricas: a maior parte dos respondentes informa nenhum dia de saúde mental ou física ruim no último mês, enquanto uma parcela menor relata muitos dias de comprometimento.

Tabela 1. Estatísticas descritivas das variáveis contínuas e ordinais ($n = 70.692$).
Age, GenHlth, Education e Income são códigos ordinais.

Variável	Média	Desv.	Mín.	Q1	Med.	Q3	Máx.
BMI	29,86	7,11	12	25	29	33	98
MentHlth	3,75	8,16	0	0	0	2	30
PhysHlth	5,81	10,06	0	0	0	6	30
GenHlth	2,84	1,11	1	2	3	4	5
Age	8,58	2,85	1	7	9	11	13
Education	4,92	1,03	1	4	5	6	6
Income	5,70	2,18	1	4	6	8	8

A Figura 1 confirma visualmente a assimetria do BMI. A maior concentração está entre 20 e 40, mas existe uma cauda longa à direita, com poucos registros muito acima da faixa central. Esses pontos extremos podem afetar algoritmos baseados em distância, principalmente K-Means e Agglomerative, pois aumentam artificialmente a distância entre observações. Por isso, o BMI foi posteriormente limitado à faixa de 12 a 60, medida que preserva os registros, mas reduz a influência dos valores mais extremos.




Figura 1. Histograma do índice de massa corporal (BMI). A distribuição é concentrada na faixa de 20 a 40 e apresenta cauda longa à direita.

A Figura 2 mostra a proporção de respostas iguais a 1 nas variáveis binárias. Duas variáveis se destacam por serem quase constantes: `CholCheck` (97,5%) e `AnyHealthcare` (95,5%). Variáveis desse tipo tendem a contribuir pouco para separar grupos, pois quase todos os respondentes têm o mesmo valor. Em contraste, `HighBP` (56,3%), `HighChol` (52,6%), `Smoker` (47,5%) e `DiffWalk` (25,3%) possuem variação suficiente e representam fatores importantes para a definição de perfis de risco.




Figura 2. Proporção de respostas iguais a 1 nas variáveis binárias, ordenadas de forma decrescente.

3.2. Análise Bivariada

Na análise bivariada foram calculadas correlações de Pearson e Spearman entre as variáveis numéricas e ordinais. Como parte das variáveis é ordinal e possui poucos valores possíveis, a correlação de Spearman é especialmente útil por capturar relações monotônicas sem exigir linearidade estrita. Os pares com maior associação por Spearman foram GenHlth–PhysHlth ($\rho = 0,52$), Education–Income ($\rho = 0,46$) e GenHlth–Income ($\rho = -0,38$).

Esses resultados são coerentes com o domínio. Quanto pior a saúde geral percebida, maior tende a ser o número de dias de saúde física ruim. Ao mesmo tempo, maior escolaridade aparece associada a maior renda. A correlação negativa entre GenHlth e Income também é interpretável, pois valores maiores de GenHlth indicam pior saúde geral; assim, maior renda tende a estar associada a melhor autopercepção de saúde.




Figura 3. Relação entre GenHlth e PhysHlth em uma amostra de 5.000 pontos.
O uso de *jitter* facilita a visualização de variáveis discretas.

A Figura 3 ilustra a associação entre GenHlth e PhysHlth. Embora haja dispersão considerável, observa-se uma tendência crescente: respondentes com pior avaliação de saúde geral relatam mais dias de saúde física ruim. Nenhum par de variáveis apresentou correlação próxima de $\pm 0,9$, limiar que indicaria redundância forte. Assim, nenhuma variável foi removida por correlação excessiva.

3.3. Análise Multivariada

A Figura 4 apresenta o *heatmap* da correlação de Spearman considerando as 21 variáveis preditoras. A matriz sugere dois conjuntos principais de relações. O primeiro envolve fatores de risco e condição de saúde, como HighBP, HighChol, HeartDiseaseorAttack, Stroke, DiffWalk, PhysHlth e GenHlth. O segundo envolve variáveis socioeconômicas, especialmente Education e Income. A presença desses blocos indica que os dados possuem estrutura interna, mas não necessariamente clusters bem separados.




Figura 4. Matriz de correlação de Spearman das 21 variáveis preditoras. Tons avermelhados representam correlações positivas e tons azulados representam correlações negativas.

Para complementar a análise multivariada, foi aplicada Análise de Componentes Principais (PCA) sobre os dados padronizados. A Figura 5 mostra que a primeira componente explica 17,3% da variância e as duas primeiras explicam, juntas, 25,6%. Para atingir cerca de 90% da variância acumulada, seriam necessárias 17 das 21 componentes. Isso mostra que a informação não se concentra em poucas dimensões dominantes. Consequentemente, espera-se que os algoritmos encontrem mais um gradiente contínuo de risco do que grupos compactos e naturalmente separados.




Figura 5. Variância explicada pelo PCA. A linha tracejada indica 90% de variância acumulada, atingida apenas na 17ª componente.

4. Pré-processamento

O pré-processamento foi definido a partir das exigências do trabalho e dos resultados da análise descritiva. As etapas realizadas foram:

1. **Verificação de valores faltantes:** não foram encontrados valores NaN. Assim, não foi necessária imputação.
2. **Remoção de colunas desnecessárias:** não havia colunas de ID, nome, data ou índices artificiais no arquivo utilizado.
3. **Tratamento de outliers:** a variável BMI foi limitada à faixa de 12 a 60. A estratégia de *clipping* foi escolhida para reduzir o impacto de valores extremos sem excluir observações da base.
4. **Separação do rótulo:** a coluna `Diabetes_binary` foi removida da matriz de entrada. Ela foi armazenada separadamente e utilizada apenas na avaliação externa dos clusters.
5. **Padronização:** todas as variáveis foram transformadas com `StandardScaler`, ficando com média zero e desvio padrão um. Esse passo é necessário porque os algoritmos utilizados dependem de distâncias e, sem padronização, variáveis com maior escala, como BMI ou `Income`, poderiam dominar as variáveis binárias.
6. **Uso do PCA:** o PCA foi empregado para diagnóstico e visualização em duas dimensões. Como seriam necessárias 17 componentes para preservar aproximadamente 90% da variância, a clusterização foi realizada no espaço original padronizado de 21 variáveis, preservando a interpretabilidade dos perfis.

Por custo computacional, os algoritmos Agglomerative Clustering e DBSCAN foram executados sobre uma amostra aleatória fixa de 7.000 instâncias. O K-Means foi executado sobre o conjunto completo de 70.692 instâncias. Essa diferença deve ser considerada na comparação das métricas, principalmente no índice Calinski-Harabasz, que é sensível ao número de pontos avaliados.

5. Algoritmos, Hiperparâmetros e Critérios de Avaliação

Foram implementados três algoritmos da biblioteca *scikit-learn*: K-Means, Agglomerative Clustering e DBSCAN. Para cada algoritmo foram testadas múltiplas configurações de hiperparâmetros. A comparação interna foi feita com três métricas:

- **Silhouette Score:** mede o quanto cada ponto está mais próximo de seu próprio cluster do que dos demais; valores maiores indicam melhor separação.
- **Davies-Bouldin Index:** compara a dispersão interna dos clusters com a distância entre eles; valores menores indicam melhor partição.
- **Calinski-Harabasz Score:** mede a razão entre separação entre clusters e compactação interna; valores maiores indicam melhor estrutura.

Como as métricas enfatizam propriedades diferentes, a escolha final não foi feita de forma automática por uma única métrica. Também foi considerada a interpretabilidade dos grupos, o tamanho dos clusters e a presença de partições degeneradas.

5.1. K-Means

No K-Means foram testados valores de k entre 2 e 10, usando `n_init = 10`. A Tabela 2 resume os resultados. O melhor *Silhouette* ocorreu em $k = 2$ (0,167), e os demais valores de k apresentaram queda acentuada. Embora o índice Davies-Bouldin diminua para alguns valores maiores de k , o ganho não é acompanhado por melhor *Silhouette* nem por maior clareza interpretativa. Assim, $k = 2$ foi selecionado como a configuração mais adequada.

Tabela 2. K-Means: métricas internas em função do número de clusters.

k	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	0,167	2,544	9645
3	0,077	2,883	7170
4	0,084	2,535	6391
5	0,085	2,317	5920
6	0,091	2,244	5509
7	0,100	2,079	5476
8	0,095	2,250	5050
9	0,083	2,133	5119
10	0,103	2,069	5021

A Figura 6 reforça essa escolha. O gráfico do cotovelo mostra queda contínua da inércia, sem ponto de inflexão claro. Quando isso acontece, o método do cotovelo não oferece uma decisão evidente. O gráfico de *Silhouette*, por sua vez, apresenta máximo em $k = 2$. A escolha de dois clusters também é coerente com o problema proposto, pois permite comparar um perfil de maior risco com outro de menor risco.




Figura 6. K-Means. À esquerda, queda da inércia pelo método do cotovelo. À direita, *Silhouette* em função de k , com maior valor em $k = 2$.

5.2. Agglomerative Clustering

Para o Agglomerative Clustering foram avaliados os métodos de ligação *ward*, *complete*, *average* e *single*, com $k \in \{2, 3, 4, 5\}$. A Tabela 3 apresenta configurações representativas. Os métodos *average* e *single* obtiveram *Silhouette* mais alto em algumas configurações, mas produziram partições degeneradas: o menor cluster ficou com menos de 3% dos pontos, e no caso de *average* com $k = 2$ apenas 0,06% da amostra ficou no menor grupo. Nesses casos, a métrica fica artificialmente alta porque o algoritmo isola poucos pontos extremos e mantém quase toda a amostra no outro cluster.

Para evitar essa interpretação enganosa, foi adotado o critério de que o menor cluster deveria conter pelo menos 5% da amostra. Com esse critério, a melhor configuração foi *complete* com $k = 2$, com *Silhouette* de 0,178 e menor cluster contendo 12,5% dos pontos.

Tabela 3. Agglomerative Clustering: configurações representativas na amostra de 7.000 instâncias.

Linkage	k	Menor cluster	Silhouette	D-B	C-H
ward	2	0,371	0,111	3,140	634
complete	2	0,125	0,178	2,662	458
complete	3	0,025	0,192	2,180	440
average	2	0,001	0,341	1,199	9
single	2	0,025	0,327	1,285	377

O dendrograma da Figura 7, gerado com *ward* em uma subamostra de 1.500 pontos, mostra que existem grandes ramos na estrutura hierárquica. No entanto, a ausência de saltos muito pronunciados indica que a separação entre grupos não é forte. Isso é compatível com os baixos valores de *Silhouette*: a hierarquia permite dividir a base em grupos, mas esses grupos não são naturalmente bem isolados.




Figura 7. Dendrograma do Agglomerative Clustering com *linkage ward* em subamostra de 1.500 pontos.

5.3. DBSCAN

O DBSCAN foi avaliado com $\varepsilon \in \{1,0; 1,5; 2,0; 2,5; 3,0\}$ e $\text{min_samples} \in \{5, 10, 20, 50\}$. Antes da busca, foi analisado o gráfico de *k-distance*, apresentado na Figura 8. O joelho aproximado aparece entre 3,0 e 4,0 no espaço padronizado. Como a grade de testes foi até 3,0, esse valor foi incluído como candidato principal.

A Tabela 4 mostra o principal desafio do DBSCAN neste conjunto. Configurações com *Silhouette* mais alto, como $\varepsilon = 1,0$ e $\text{min_samples}=20$, classificaram quase todos os pontos como ruído (6.783 de 7.000). Esse resultado não é útil para o problema, pois não produz uma segmentação interpretável da população. Por isso, foi adotado o critério de menos de 50% de ruído e entre 2 e 10 clusters. A melhor configuração válida foi $\varepsilon = 3,0$ e $\text{min_samples}=10$, produzindo 7 clusters e 1.564 pontos de ruído, com *Silhouette* de 0,137.

Tabela 4. DBSCAN: configurações selecionadas na amostra de 7.000 instâncias.

ε	min_samples	Clusters	Ruído	Silhouette
1,0	20	2	6783	0,408
1,5	50	3	6591	0,323
2,0	50	12	5702	0,253
3,0	5	14	1165	0,147
3,0	10	7	1564	0,137




Figura 8. DBSCAN. À esquerda, gráfico de *k-distance* para estimar ε . À direita, clusters projetados em duas componentes principais; os pontos em cinza representam ruído.

A projeção em PCA 2D evidencia que o DBSCAN encontra um grande cluster central e pequenos grupos locais, além de uma quantidade expressiva de pontos rotulados como ruído. Isso sugere que os dados não possuem regiões de densidade muito bem separadas, especialmente em um espaço de 21 dimensões padronizadas.

6. Comparação entre os Algoritmos

A Tabela 5 reúne a melhor configuração selecionada para cada algoritmo. A Figura 9 apresenta a mesma comparação de forma visual. Nenhum algoritmo domina simultaneamente nas três métricas: Agglomerative tem o maior *Silhouette*, DBSCAN tem o menor Davies-Bouldin e K-Means apresenta o maior Calinski-Harabasz.

Tabela 5. Comparação entre as melhores configurações dos algoritmos.

Algoritmo	Configuração	Clusters	Silhouette	D-B	C-H
K-Means	$k = 2$	2	0,167	2,544	9645
Agglomerative	<i>complete</i> , $k = 2$	2	0,178	2,662	458
DBSCAN	$\varepsilon = 3, 0$, m.s.= 10	7	0,137	1,478	153




Figura 9. Comparação das métricas internas entre os algoritmos. Cada métrica favorece uma propriedade diferente da partição.

A interpretação da Figura 9 exige cuidado. O *Silhouette* de todos os métodos é baixo, sempre abaixo de 0,18 nas configurações selecionadas. Isso indica que os grupos se sobrepõem e não estão bem separados. O DBSCAN obtém o melhor Davies-Bouldin porque descarta uma parte dos pontos como ruído, ficando com subconjuntos mais homogêneos. Já o Calinski-Harabasz do K-Means é muito maior porque esse algoritmo foi avaliado no conjunto completo, enquanto Agglomerative e DBSCAN foram avaliados na amostra de 7.000 instâncias. Portanto, a comparação das métricas deve ser usada como apoio, e não como critério único.

As projeções em PCA 2D da Figura 10 ajudam a entender as diferenças qualitativas. O K-Means separa a nuvem principalmente ao longo da primeira componente principal, produzindo uma fronteira relativamente limpa. O Agglomerative, por outro lado, separa uma região mais extrema da nuvem e mantém maior sobreposição visual entre os grupos. Em ambos os casos, a figura confirma que há gradientes de risco, mas não fronteiras naturais rígidas.




Figura 10. Clusters projetados em duas componentes principais. À esquerda, K-Means com $k = 2$; à direita, Agglomerative com *complete* e $k = 2$.

Considerando desempenho, escalabilidade e interpretabilidade, o K-Means foi o algoritmo mais adequado para o objetivo do trabalho. Ele foi o único executado na base completa, produziu dois grupos coerentes com a pergunta inicial e apresentou o maior alinhamento externo com o rótulo de diabetes, como discutido na próxima seção.

7. Interpretação dos Clusters com o Rótulo Original

Após a clusterização, o rótulo `Diabetes_binary` foi reintroduzido para avaliação externa. A Tabela 6 apresenta o Adjusted Rand Index (ARI), que mede a concordância entre os clusters e o rótulo original corrigindo acordos ao acaso. O K-Means obteve o maior valor (0,113), seguido pelo Agglomerative (0,021) e pelo DBSCAN (0,008). Todos os valores são baixos, o que mostra que os clusters não reproduzem diretamente a classe de diabetes.

Tabela 6. Alinhamento externo entre os clusters e o rótulo original de diabetes.

Algoritmo	ARI
K-Means	0,113
Agglomerative	0,021
DBSCAN	0,008

Esse resultado não invalida a clusterização. Ele indica que o diagnóstico de diabetes não é determinado por uma única fronteira natural no espaço dos indicadores. Em vez disso, os algoritmos capturam perfis de risco, e esses perfis apenas aumentam ou diminuem a concentração de pessoas com diabetes. Em saúde, esse comportamento é esperado: indivíduos sem diabetes podem apresentar vários fatores de risco, enquanto pessoas com diabetes podem ter perfis variados.

A interpretação mais clara foi obtida com o K-Means. A Tabela 7 mostra o perfil médio dos dois clusters. O Cluster 0 concentra respondentes com pressão alta, colesterol alto, maior BMI, pior saúde geral, mais dias de saúde física ruim e maior dificuldade de locomoção. A taxa de diabetes nesse grupo é 75,2%. O Cluster 1 apresenta perfil mais favorável: menores proporções de pressão e colesterol altos, menor BMI, melhor saúde geral, menos dias de saúde física ruim e menor dificuldade de locomoção. Nesse grupo, a taxa de diabetes é 37,4%.

Tabela 7. Perfil médio dos clusters do K-Means. A taxa de diabetes foi usada apenas para interpretação externa, pois o rótulo não participou da clusterização.

Variável	Cluster 0 alto risco	Cluster 1 menor risco
<i>n</i> (pessoas)	23.515	47.177
HighBP	0,81	0,44
HighChol	0,71	0,43
BMI	32,58	28,42
GenHlth (1–5)	3,84	2,34
Age (faixa)	9,46	8,15
DiffWalk	0,67	0,04
PhysHlth (dias)	14,29	1,58
Education	4,39	5,19
Income	4,14	6,47
Taxa de diabetes	0,752	0,374

A diferença entre os grupos é substantiva. A prevalência de pressão alta no Cluster 0 é quase o dobro da observada no Cluster 1. A dificuldade de locomoção é ainda mais discriminante: 67% no Cluster 0 contra apenas 4% no Cluster 1. Além disso, o Cluster 0 apresenta menor escolaridade e menor renda médias, reforçando que os fatores metabólicos e socioeconômicos aparecem combinados no perfil de maior risco.

A Tabela 8 apresenta a contingência entre clusters e rótulo no K-Means. O Cluster 0 contém 17.694 pessoas com diabetes e 5.821 sem diabetes, enquanto o Cluster 1 contém 17.652 pessoas com diabetes e 29.525 sem diabetes. Portanto, embora a separação não seja perfeita, há enriquecimento claro: os casos de diabetes ficam proporcionalmente mais concentrados no cluster de alto risco.

Tabela 8. Tabela de contingência entre clusters do K-Means e o rótulo *Diabetes_binary*.

	Sem diabetes (0)	Com diabetes (1)
Cluster 0 (alto risco)	5.821	17.694
Cluster 1 (menor risco)	29.525	17.652

8. Discussão Geral

Os resultados mostram que o conjunto de indicadores de saúde possui estrutura suficiente para formar perfis interpretáveis, mas não apresenta clusters bem separados. Essa conclusão aparece de forma consistente em várias partes do experimento. Primeiro, o PCA mostrou que as duas primeiras componentes explicam apenas 25,6% da variância, o que indica que não há poucas dimensões capazes de resumir a base. Segundo, as métricas internas, especialmente o *Silhouette*, ficaram baixas para todos os algoritmos. Terceiro, os valores de ARI também foram baixos, indicando que os clusters não coincidem fortemente com o rótulo de diabetes.

A leitura conjunta das tabelas e figuras sugere que a população da base é mais bem descrita por um gradiente contínuo de risco do que por categorias naturais rígidas. Em uma extremidade estão indivíduos com maior pressão, colesterol, BMI, pior saúde geral, mais limitações físicas e menor renda. Na outra extremidade estão indivíduos com indicadores mais favoráveis. O K-Means capturou esse eixo de variação de forma simples e interpretável, separando a base em dois perfis principais.

O Agglomerative Clustering também encontrou uma divisão de risco, mas foi limitado pelo custo computacional e precisou ser executado em amostra. Além disso, algumas configurações com melhor métrica interna geraram clusters muito pequenos, mostrando que a seleção de hiperparâmetros não pode depender apenas do maior *Silhouette*. O DBSCAN foi o menos adequado ao problema, pois os dados não apresentaram regiões densas suficientemente separadas; por isso, o algoritmo rotulou muitos pontos como ruído ou criou pequenos clusters pouco representativos.

Também é importante destacar uma limitação do conjunto utilizado. Como a base é balanceada em relação ao rótulo de diabetes, as proporções de diabetes dentro dos clusters não representam prevalência populacional. Elas são úteis para comparar grupos entre si, mas não para estimar a frequência real da doença. Ainda assim, a diferença entre 75,2% no cluster de alto risco e 37,4% no cluster de menor risco é forte o suficiente para indicar que os grupos possuem significado prático.

9. Conclusão

O objetivo do trabalho foi investigar se algoritmos de clustering seriam capazes de separar respondentes do BRFSS em perfis de risco de diabetes sem utilizar o diagnóstico durante a

clusterização. A resposta é positiva, mas com ressalvas. Os algoritmos não encontraram grupos naturais fortemente separados, porém o K-Means produziu uma divisão clara e interpretável entre um grupo de alto risco metabólico e outro de menor risco.

Entre os métodos avaliados, o K-Means foi considerado o mais adequado porque rodou sobre a base completa, apresentou boa interpretabilidade e obteve o maior alinhamento com o rótulo externo. O Agglomerative Clustering produziu resultados úteis na amostra, mas foi mais sensível à formação de clusters pequenos. O DBSCAN mostrou-se menos apropriado para este conjunto, devido à alta proporção de ruído e à dificuldade de identificar regiões densas em 21 dimensões.

As variáveis que mais diferenciaram os perfis foram HighBP, HighChol, BMI, GenHlth, PhysHlth, DiffWalk, Education e Income. Esses resultados são coerentes com o conhecimento sobre diabetes tipo 2, pois combinam fatores metabólicos, condição física percebida e fatores socioeconômicos. Assim, mesmo com métricas internas modestas, a clusterização cumpriu seu papel exploratório: identificou subpopulações com perfis de risco distintos e auxiliou na interpretação dos fatores associados ao diagnóstico de diabetes na base.

Referências

- [1] Centers for Disease Control and Prevention. *Behavioral Risk Factor Surveillance System Survey Data and Documentation*. Atlanta: U.S. Department of Health and Human Services, Centers for Disease Control and Prevention, 2015.
- [2] Teboul, A. *Diabetes Health Indicators Dataset*. Kaggle, 2021.
- [3] Xie, F., Chakraborty, B., Ong, M. E. H., Goldstein, B. A. and Liu, N. (2019). Building risk prediction models for type 2 diabetes using machine learning techniques. *Preventing Chronic Disease*, 16:190109.