

Aprendizado Supervisionado com Seleção de Features e Otimização de Hiperparâmetros aplicado a Indicadores de Saúde para Diabetes

Ana Lilian Alfonso Toledo, Tobias Viero de Oliveira

Curso de Ciência da Computação
Universidade Federal de Santa Maria (UFSM)

1. Etapa 1 - Escolha e Análise do Dataset

1.1. Descrição do problema e procedência

O *dataset* utilizado é o *CDC Diabetes Health Indicators*, derivado do *Behavioral Risk Factor Surveillance System* (BRFSS) de 2015, uma pesquisa telefônica anual conduzida pelos *Centers for Disease Control and Prevention* (CDC) dos Estados Unidos. A escolha justifica-se pela procedência institucional (órgão público de saúde), pela ampla utilização do BRFSS em estudos de fatores de risco para diabetes e pela disponibilidade pública no Kaggle. O *dataset* relaciona indicadores de estilo de vida, condições clínicas e fatores socioeconômicos ao diagnóstico de diabetes, problema de alta relevância epidemiológica.

O mesmo conjunto de dados é reaproveitado nas três tarefas exigidas, conforme a Tabela 1: a versão binária para classificação binária, a versão de três classes para a multiclasse, e a versão binária (reaproveitada) tomando o IMC (*BMI*) como alvo contínuo na regressão.

Tabela 1: Mapeamento das três tarefas sobre a mesma família de dados.

Tarefa	Arquivo	Alvo	Amostras
Classificação binária	diabetes_binary	Diabetes_binary	253.680
Classificação multiclasse	diabetes_012	Diabetes_012	253.680
Regressão	diabetes_binary	BMI	253.680

1.2. Amostras, atributos e variável alvo

O *dataset* possui 253.680 amostras e 21 atributos preditores (mais a variável alvo). Os atributos dividem-se em: 14 binárias (HighBP, HighChol, CholCheck, Smoker, Stroke, HeartDiseaseorAttack, PhysActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, DiffWalk, Sex), 4 ordinais (GenHlth 1–5, Age em 13 faixas etárias, Education 1–6, Income 1–8) e 3 numéricas (BMI, MentHlth e PhysHlth, estas duas em dias de 0 a 30).

1.3. Distribuição das classes

A Figura 1 apresenta a distribuição das classes. O alvo binário é desbalanceado, com 86,07% de não-diabéticos e 13,93% de diabéticos. O alvo multiclasse é severamente

desbalanceado: 84,24% sem diabetes (classe 0), apenas 1,83% de pré-diabéticos (classe 1) e 13,93% de diabéticos (classe 2).




Figura 1: Distribuição das classes nas tarefas binária (esq.) e multiclasse (dir.).

1.4. Possíveis problemas encontrados

Valores ausentes. O *dataset* publicado já vem limpo: foram encontradas 0 células ausentes. Ainda assim, o pré-processamento implementa imputação para cumprir o requisito e dar robustez a novas amostras.

Classes desbalanceadas. Presentes em ambas as tarefas de classificação, de forma severa na multiclasse (classe de pré-diabetes < 2%), o que motiva o uso de `class_weight='balanced'` e de métricas robustas (ROC-AUC, PR-AUC, F1-macro).

Outliers. O BMI varia de 12 a 98, com cerca de 9.820 valores acima do limite superior do IQR (41,5), conforme a Figura 2. As variáveis *MentHlth* e *PhysHlth* apresentam forte concentração em zero (*zero-inflation*).

Correlação elevada. Apenas o par *GenHlth*–*PhysHlth* ultrapassa $|r| \geq 0,5$ ($r = 0,524$); logo abaixo desse limiar aparecem os eixos de saúde (*GenHlth*–*DiffWalk*) e socioeconômico (*Education*–*Income*), conforme o mapa de calor da Figura 3. Não há multicolinearidade extrema, mas a redundância parcial reforça a utilidade da seleção de *features*.




Figura 2: Distribuição do BMI (histograma e *boxplot*), evidenciando a cauda de *outliers*.

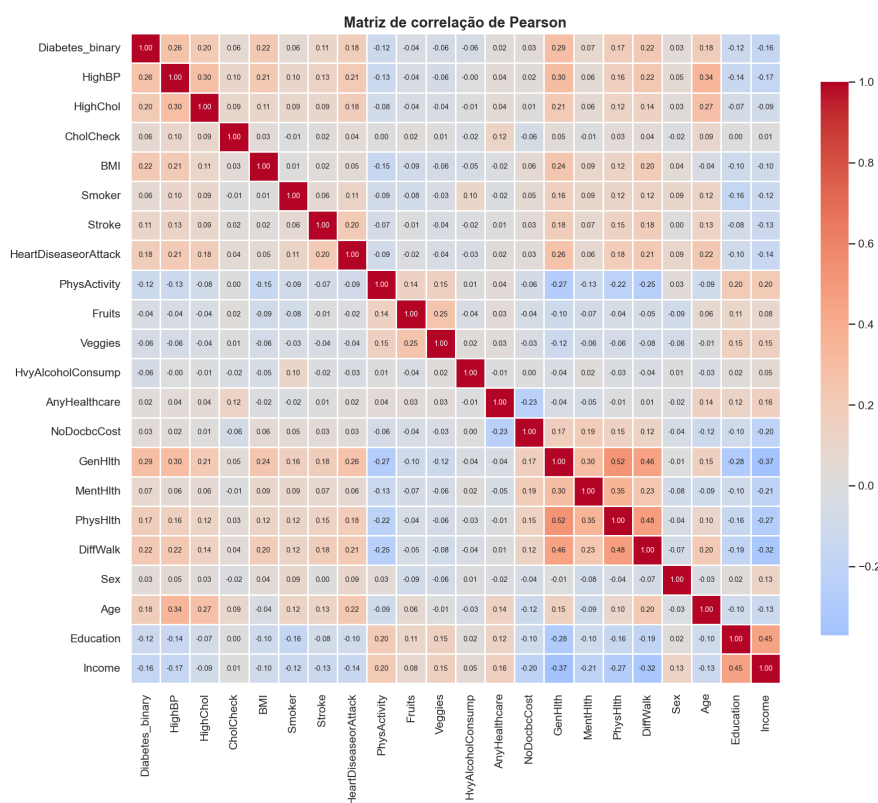


Figura 3: Mapa de calor de correlação de Pearson entre os atributos.

2. Etapa 2 - Pré-processamento

A Tabela 2 resume as decisões de pré-processamento e suas justificativas. Os dados foram divididos de forma estratificada em treino/validação/teste (60/20/20), garantindo a mesma proporção de classes nos três conjuntos. Todas as transformações (*imputer*, *scaler*) são ajustadas apenas no conjunto de treino e aplicadas a validação e teste por meio de *ColumnTransformer*, prevenindo vazamento de dados (*data leakage*). O conjunto de teste é avaliado uma única vez ao final de cada tarefa.

Tabela 2: Escolhas de pré-processamento e justificativas.

Aspecto	Escolha	Justificativa
Ausentes (numéricas)	Imputação pela mediana (SimpleImputer)	Mediana é robusta aos <i>outliers</i> de BMI/MentHlth/PhysHlth.
Ausentes (binárias)	Imputação pela moda (SimpleImputer)	Moda é a estatística adequada para variáveis 0/1.
Encoding	Manter codificação numérica original	Binárias já são 0/1; ordinais possuem ordem natural – evita-se <i>One-Hot</i> para não perder a ordem nem inflar a dimensão.
Scaling	StandardScaler (ordinais+numéricas); <i>passthrough</i> binárias	Padroniza escalas distintas (ex.: BMI 12–98 vs. dias 0–30) e acelera a convergência da MLP.
Desbalanceamento	<code>class_weight='balanced'</code>	Compensa classes minoritárias sem alterar os dados.

3. Etapa 3 - Seleção de Features

3.1. Técnica escolhida e justificativa

A técnica adotada foi a *Mutual Information* (MI), via `mutual_info_classif` (classificação) e `mutual_info_regression` (regressão), calculada sobre o conjunto de treino. A MI foi escolhida por capturar dependências não lineares (coerente com o uso de MLP), por lidar naturalmente com a mistura de variáveis binárias, ordinais e numéricas e por possuir variante tanto para classificação quanto para regressão, garantindo consistência metodológica entre as três tarefas.

3.2. Ranking e critério de seleção

A Figura 4 mostra o *ranking* de importância na tarefa binária. O critério de corte adotado mantém as *features* de maior MI até que a MI acumulada atinja 90% da MI total. Com isso, o número de atributos foi reduzido de 21 para 11 (binária e multiclasse) e para 12 (regressão), conforme a Tabela 3. Para diabetes, os atributos de maior MI foram GenHlth, HighBP, BMI, HighChol e Age.




Figura 4: Ranking de *Mutual Information* dos atributos (tarefa binária).

Tabela 3: Quantidade de *features* antes e depois da seleção.

Tarefa	Inicial	Selecionadas	Descartadas
Binária	21	11	10
Multiclasse	21	11	10
Regressão	21	12	9

3.3. Comparação: todas as features vs. features selecionadas

A Tabela 4 e a Figura 5 comparam a MLP *baseline* treinada com todas as *features* e apenas com as selecionadas.

Tabela 4: Comparação todas × selecionadas (métrica principal no teste: ROC-AUC binária, F1-macro multiclasse, R^2 regressão).

Tarefa	Conjunto	#Feat.	Métrica teste	Gap tr-val	Tempo (s)
Binária	Todas	21	0,8262	0,0081	29,6
	Selecionadas	11	0,8215	0,0061	24,4
Multiclasse	Todas	21	0,4235	0,0044	22,8
	Selecionadas	11	0,4181	0,0050	37,8
Regressão	Todas	21	0,1736	0,0009	95,3
	Selecionadas	12	0,1663	0,0011	125,8




Figura 5: Comparação de desempenho entre todas as *features* e as selecionadas.

Discussão. A seleção mantém a métrica praticamente inalterada (quedas da ordem de 0,5–1 ponto) usando cerca de metade dos atributos. O *overfitting* já é baixo em todas as tarefas (forte regularização do *early stopping* e do *class_weight*), e a seleção não o aumenta de forma relevante – na binária, inclusive, o *gap* treino-validação diminuiu ($0,0081 \rightarrow 0,0061$). Quanto ao tempo de treinamento, menos atributos reduzem o número de parâmetros e o custo *por época*, mas o tempo de parede total depende de quantas épocas o *early stopping* permite: na binária o tempo caiu, porém na multiclasse e na regressão o modelo selecionado convergiu em mais épocas, elevando o tempo total (efeito do *early stopping*, não do tamanho do modelo). A principal vantagem prática é a interpretabilidade: com menos atributos, o modelo torna-se mais fácil de explicar, e o *ranking* de MI já evidencia os fatores mais associados ao diagnóstico.

4. Etapa 4 - Classificação com MLP

4.1. Arquitetura e justificativa

A MLP *baseline* segue a estrutura $\text{Input} \rightarrow \text{Dense}(64, \text{ReLU}) \rightarrow \text{Dropout}(0, 3) \rightarrow \text{Dense}(32, \text{ReLU}) \rightarrow \text{saída}$, implementada em TensorFlow/Keras. As escolhas (Tabela 5) priorizam um modelo compacto e estável: duas camadas ocultas bastam para capturar interações não lineares sem *overfitting* excessivo; ReLU evita saturação de gradiente; Adam oferece convergência rápida; e o *early stopping* dispensa a fixação manual do número de épocas. A saída usa *sigmoid* (binária) ou *softmax* (multiclasse), com *losses binary* e *sparse categorical crossentropy*, respectivamente, e *class_weight='balanced'*.

Tabela 5: Hiperparâmetros da MLP *baseline* de classificação.

Hiperparâmetro	Valor
Camadas ocultas	2 (64 e 32 neurônios)
Ativação (ocultas)	ReLU
<i>Dropout</i>	0,3
Otimizador	Adam
<i>Learning rate</i>	10^{-3}
<i>Batch size</i>	256
Épocas	até 100 com <i>early stopping</i> (<i>patience</i> 10)

4.2. Avaliação - Classificação binária

No conjunto de teste, a MLP atingiu Acurácia 0,712, Precisão 0,300, Revocação 0,806, F1 0,438, ROC-AUC 0,826 e PR-AUC 0,418. A combinação de revocação alta com precisão baixa é esperada e desejável neste contexto de triagem clínica com desbalanceamento: o modelo prioriza identificar a maioria dos diabéticos (verdadeiros positivos), à custa de mais falsos positivos. A Figura 6 reúne a curva de aprendizado, a evolução da métrica, a curva ROC e a matriz de confusão.




Figura 6: Tarefa binária: curva de *loss* (sup. esq.), curva ROC (sup. dir.), evolução da métrica (inf. esq.) e matriz de confusão (inf. dir.).

4.3. Avaliação – Classificação multiclasse

Na multiclasse, a MLP obteve Acurácia 0,637, Precisão-macro 0,445, Revocação-macro 0,521 e F1-macro 0,424 no teste. A matriz de confusão (Figura 7) evidencia a dificuldade da classe de pré-diabetes (classe 1, < 2% das amostras), frequentemente confundida com as demais, um efeito direto do desbalanceamento severo, apenas parcialmente mitigado pelo `class_weight`.




Figura 7: Tarefa multiclasse: curva de *loss* (esq.) e matriz de confusão (dir.).

4.4. Comparação com modelos clássicos

A Tabela 6 compara a MLP com modelos clássicos. Na binária, MLP (0,826) e XGBoost (0,823) lideram em ROC-AUC, à frente da Regressão Logística (0,820) e do Random Forest (0,796). Os modelos clássicos, contudo, treinam em frações de segundo, contra ~ 18 s da MLP – um *trade-off* de custo computacional relevante quando o ganho de desempenho é marginal.

Tabela 6: MLP vs. modelos clássicos (conjunto de teste).

Tarefa	Modelo	Métrica	Tempo treino (s)
Binária (ROC-AUC)	MLP	0,826	18,1
	XGBoost	0,823	0,70
	Regressão Logística	0,820	0,18
	Random Forest	0,796	2,18
Multiclasse (F1-macro)	MLP	0,424	13,8
	Regressão Logística	0,426	0,96
	XGBoost	0,400	1,27
	Random Forest	0,383	2,25

5. Etapa 5 - Regressão com MLP

5.1. Arquitetura e justificativa

Para a regressão do BMI, a MLP *baseline* usa $\text{Input} \rightarrow \text{Dense}(64, \text{ReLU}) \rightarrow \text{Dropout}(0,2) \rightarrow \text{Dense}(32, \text{ReLU}) \rightarrow \text{Dense}(1, \text{linear})$, com *loss* MSE, métrica MAE, otimizador Adam (10^{-3}), *batch* 256 e *early stopping*. O *dropout* foi reduzido a 0,2 por ser uma tarefa de regressão (menos propensa a *overfitting* agressivo aqui).

5.2. Avaliação

No teste, a MLP obteve MAE 4,19, MSE 36,29, RMSE 6,02 e R^2 0,174. O R^2 modesto é esperado e honesto: os indicadores de saúde explicam apenas parte da variância do IMC, que depende de fatores não capturados pelo *dataset* (dieta detalhada, genética, composição corporal). As Figuras 8 e 9 mostram valores reais vs. preditos, os resíduos e a curva de aprendizado.




Figura 8: Regressão: valores reais vs. preditos (esq.) e curva de *loss* (dir.).




Figura 9: Análise de resíduos da regressão do BMI.

5.3. Comparação com modelos clássicos

A Tabela 7 mostra que MLP ($R^2 = 0,174$) e XGBoost ($R^2 = 0,170$) empatam tecnicamente na liderança, à frente dos modelos lineares ($R^2 = 0,137$) e do Random Forest ($R^2 = 0,052$). A pequena diferença confirma que o teto de desempenho é imposto pelos dados, e não pela capacidade do modelo.

Tabela 7: MLP vs. modelos clássicos na regressão do BMI (teste).

Modelo	MAE	RMSE	R^2
MLP	4,19	6,02	0,174
XGBoost	4,20	6,04	0,170
Regressão Linear / Ridge	4,32	6,16	0,137
Lasso	4,32	6,16	0,137
Random Forest	4,55	6,45	0,052

6. Etapa 6 - Otimização de Hiperparâmetros com Optuna

6.1. Espaço de busca

A MLP de cada tarefa foi otimizada com Optuna (40 *trials*, *MedianPruner*). O espaço de busca contemplou: número de camadas (1–4), neurônios por camada ($\{32, 64, 128, 256\}$), ativação (*relu*, *tanh*, *elu*), *dropout* (0–0,5), *learning rate* (10^{-4} – 10^{-2} , log), otimizador (*adam*, *rmsprop*, *sgd*), *batch size* ($\{64, 128, 256, 512\}$) e *weight decay* L2 (10^{-6} – 10^{-2} , log). A função objetivo maximiza ROC-AUC (binária) ou F1-macro (multiclasse) e minimiza RMSE (regressão), avaliada na validação. As Figuras 10 e 11 mostram o histórico de otimização e a importância dos hiperparâmetros para a tarefa binária.




Figura 10: Optuna (binária): histórico de otimização (esq.) e importância dos hiperparâmetros (dir.).




Figura 11: Histórico de otimização do Optuna para as tarefas multiclasse (esq.) e regressão (dir.).

6.2. Melhores hiperparâmetros e comparação

A Tabela 8 lista os melhores conjuntos encontrados e a Tabela 9 compara o modelo *baseline* com o otimizado.

Tabela 8: Melhor conjunto de hiperparâmetros por tarefa (Optuna).

Hiperparâmetro	Binária	Multiclasse	Regressão
Camadas ocultas	1 (256)	2 (256, 32)	1 (256)
Ativação	relu	elu	relu
Otimizador	adam	adam	adam
<i>Learning rate</i>	$1,3 \times 10^{-4}$	$4,2 \times 10^{-3}$	$6,9 \times 10^{-4}$
<i>Dropout</i>	0,349	0,094	0,119
L2 (<i>weight decay</i>)	$1,2 \times 10^{-5}$	$4,0 \times 10^{-3}$	$1,2 \times 10^{-3}$
<i>Batch size</i>	64	256	64

Tabela 9: Modelo *baseline* vs. otimizado (teste). Para a regressão a métrica é RMSE (menor é melhor).

Tarefa	Métrica	Baseline	Otimizado	Δ
Binária	ROC-AUC	0,8262	0,8267	+0,0005
Multiclasse	F1-macro	0,4235	0,4426	+0,0190
Regressão	RMSE	6,0244	6,0115	-0,0129

Discussão. O maior ganho ocorreu na multiclasse (+0,019 em F1-macro), tarefa em que a busca encontrou uma arquitetura mais profunda (256-32) com L2 mais forte. Na binária e na regressão os ganhos foram marginais, indicando que o *baseline* já operava próximo do teto imposto pelos dados. O custo da otimização foi significativo: o tempo de treino do modelo final subiu (ex.: de 18 s para 79 s na binária), pois os melhores modelos usam *batches* menores e mais neurônios. O *MedianPruner* podou de 15 a 24 dos 40 *trials* por tarefa, reduzindo o custo total da busca. Os hiperparâmetros mais influentes, segundo o Optuna, foram a *learning rate* e o número de neurônios/camadas.

7. Etapa 7 - Regularização e Análise de *Overfitting*

Para evidenciar o *overfitting*, treinou-se a mesma arquitetura (256-128-64) sobre uma subamostra de 8.000 exemplos (validação e teste completos), comparando uma rede sem regularização com uma rede com regularização. A Tabela 10 e a Figura 12 resumem os resultados.

Tabela 10: Rede sem vs. com regularização (tarefa binária).

Rede	Épocas	Loss treino	Loss teste	ROC-AUC teste
Sem regularização	200	0,006	2,134	0,718
Com regularização	57	0,491	0,520	0,810




Figura 12: Curvas de treino e validação: rede sem regularização (esq.) e com regularização (dir.).

7.1. Discussão

A rede sem regularização apresentou sinais claros de *overfitting*. Sua *loss* de treino cai para 0,006 enquanto a de validação sobe para 2,14 – um *gap* de 2,14 entre as duas curvas –, e a ROC-AUC de treino atinge o valor máximo de 1,0 contra apenas 0,718 no teste, uma diferença de 0,282. Esse comportamento, em que o modelo praticamente memoriza o conjunto de treino mas não generaliza, é a assinatura clássica do *overfitting*.

Para combatê-lo, foram aplicadas três técnicas de regularização de forma combinada: *Dropout* de 0,4 após cada camada oculta, regularização L2 (*weight decay*) de 0,001 sobre os pesos e *Early Stopping* configurado para monitorar a *loss* de validação, com *patience* de 10 épocas e restauração dos melhores pesos ao final do treinamento.

Essas medidas produziram melhoria expressiva no desempenho sobre dados não vistos: a ROC-AUC de teste subiu de 0,718 para 0,810, um ganho de $\Delta = +0,093$, ao passo que o *gap* entre treino e teste caiu de 0,282 para apenas 0,052. A rede com regularização foi, portanto, a estratégia de melhor equilíbrio entre desempenho e capacidade de generalização: mantém ROC-AUC alta no teste com uma diferença pequena em relação ao treino, enquanto a rede sem regularização exibiu um desempenho de treino enganosamente alto e generalizava pior. Como benefício adicional, o *Early Stopping* reduziu o custo computacional, encerrando o treinamento em 57 épocas em vez de 200, enquanto o *Dropout* e a regularização L2 limitaram a complexidade efetiva da rede.

8. Conclusão

Este trabalho implementou um pipeline supervisionado completo sobre o *CDC Diabetes Health Indicators*, cobrindo as três tarefas exigidas. A seleção por *Mutual Information* reduziu o número de atributos à metade com perda desprezível de desempenho e ganho de interpretabilidade. As MLPs alcançaram ROC-AUC de 0,827 (binária) e F1-macro de 0,443 (multiclasse, após Optuna), competitivas com modelos clássicos a um custo computacional maior. A regressão do IMC atingiu $R^2 \approx 0,17$, limite imposto pelos próprios dados. A otimização com Optuna trouxe o maior ganho na tarefa multiclasse, e a análise de regularização demonstrou, de forma quantitativa, o impacto de *Dropout*, *weight decay* e *early stopping* na capacidade de generalização da rede. Como trabalhos futuros, sugere-se a aplicação de técnicas de reamostragem (ex.: SMOTE) para mitigar o

desbalanceamento severo da classe de pré-diabetes e o uso de SHAP para validar a seleção de *features*.